

DON'T PANIC

aneb zničí nás Terminátoři?

AI Monday · 5. 10. 2026

Zničí nás AI?


Vezme nám práci?

Myslí?

Ví, co říká?

Nejvíce se bojíme toho, čemu nerozumíme.

Tak to pojďme rozebrat.



Většina věcí po mně už nikdy nefungovala.
Ale vždycky jsem se něco naučil.

Kočka sedí na ...

Kočka sedí na ...

střeše gauči zemi stole ...

Gratuluju. Právě jste si zahráli na language model.

LLM nevidí text. Dostává tokeny.

Ko	čka	· sed	í	· na	· st	ře	še	.
33185	51851	10412	556	898	420	38132	13136	13

9 tokenů

The	· cat	· sits	· on	· the	· roof	.
976	9059	38174	402	290	16367	13

7 tokenů

· = mezera · tokenizer o200k_base · počet tokenů závisí na tokenizeru a textu

Tokeny se změní na čísla

· sed → 10412 → [0.12, -0.83, 0.40, ...]

· na → 898 → [-0.51, 0.07, 0.93, ...]

· st → 420 → [0.66, 0.21, -0.18, ...]

+ pozice v textu

schematické hodnoty · reálně stovky
až tisíce čísel



schéma, ne měření

Na co se mám dívat?



Když zpracovávám tento token, které části kontextu jsou pro něj důležité?

`sytost = váha attention · schéma, ne změřené váhy · zjednodušeno: slova místo tokenů`

Opakuj. Hodněkrát.




**Žádná ručně napsaná
tabulka odpovědí.**

Architektura + miliardy naučených čísel
— parametrů.

Nevypadne odpověď. Vypadne rozdělení.

Kočka sedí na ... → logits (skóre) → **softmax** → pravděpodobnosti




ILUSTRATIVNÍ ČÍSLA
zjednodušeno: slova místo tokenů


... ostatní: 28 % dohromady, rozprostřeno mezi desítky tisíc tokenů

A teď hodíme kostkou


T = 0.2



T = 1.0



T = 1.2




syntetické logits $[3, 2, 1, 0]$ · $\text{softmax}(\text{logits} / T)$ · osa 0–100 %

Kostka, která před každým hodem změní pravděpodobnosti svých stěn — podle všeho, co zatím viděla.

Stochastický ≠ náhodný chaos.

A znovu. A znovu. A znovu.



Kočka sedí na

·st

Kočka sedí na st

ře

Kočka sedí na stře

še

Kočka sedí na střeše

.

tokeny podle o200k_base; konkrétní volby ilustrativní

Tak proč je to tak chytré?

Hlavní město Austrálie je ...

→ fakta

```
def is_even(n): return ...
```

→ kód

„Le chat dort.” = „Kočka ...

→ překlad

Pokud $A > B$ a $B > C$, pak $A > C$...

→ logická struktura

Aby model dobře předpovídal text, učí se vzory a vztahy použitelné i pro překlad, kód a řešení úloh.

Potočíme pár miliard knoflíků

text: Kočka sedí na rohožce.

model: Kočka sedí na ...

·st  40 %

·ro  3 % ilustrativní
pravděpodobnosti

skutečný další token v textu: ·ro


chyba

→ malá úprava parametrů

→ znovu


→ × **biliony tokenů**

→ pak post-training: instrukce, preference



zjednodušení

Co mají LLM společného s JPEGem?



Parametry nejsou databáze dokumentů.

LLM není JPEG. Mechanismus je úplně jiný — analogie pro intuici, ne technický popis. (A některé pasáže si model umí zapamatovat doslova.)

Proč halucinuje?

```
while not done:
    probs = model(context)
    # vždycky nějaké rozdělení
    token = sample(probs)
    context += token
```

Věrohodné pokračování není záruka pravdy.

Model může říct „nevím“.
Generování ale nezaručuje, že
správně pozná kdy.

Halucinace není cizí přívěsek nalepený na LLM.

Je to důsledek toho, že po generativním modelu chceme odpověď i tam, kde nemá spolehlivou oporu.

$$2837 \times 491 = ?$$


Kde přesně jste v té mašině viděli násobičku?

$$2837 \times 491 = ?$$



Když mám kalkulačku, použiju kalkulačku.

Tak mu dejme nástroje



RAG: nedonutíme model, aby všechno věděl.

Najdeme relevantní informace a vložíme mu je do kontextu.


Tak mu dejme nástroje



Tools: kalkulačka · search · databáze · API · Python · interní systémy

Model navrhne volání, náš kód ho provede a vrátí výsledek.

Tak mu dejme nástroje



LLM není celý agent. Je to jedna komponenta.

Agent = smyčka: zvol akci → spust' tool → přečti výsledek → pokračuj, nebo skonči.

Dva světy

DETERMINISTIC

pravidla

výpočty

validace

autorizace

DB constraints

workflows

invarianty

PROBABILISTIC

interpretace jazyka

klasifikace nejasného vstupu

extrakce

sumarizace

generování

fuzzy matching

Dosáhl 18 let?

✗



✓




Nedělej z deterministického problému probabilistický jen proto, že máš LLM.

Je to stížnost?


„No paráda, zase mi to přišlo rozbitý.“

```
if "paráda" in msg:  
    return PRAISE  
# ...a 4000 dalších výjimek
```



Tady rychle přibývají výjimky. Tady se model může hodit.

To nejlepší z obou světů



Takže... zničí nás Terminátoři?

Znalost mechanismu není důkaz bezpečnosti.

Co můžeme řídit hned: oprávnění, ověřování a lidský dohled.

DON'T PANIC ≠ don't care.

DON'T PANIC

It's just software.

Very weird software.

Don't replace certainty with probability
unless probability solves a problem certainty can't.

Kam dál

Transformer Explainer

poloclub.github.io/transformer-explainer

Vaswani et al. 2017

[Attention Is All You Need · arxiv.org/abs/1706.03762](https://arxiv.org/abs/1706.03762)

Ouyang et al. 2022

[InstructGPT · arxiv.org/abs/2203.02155](https://arxiv.org/abs/2203.02155)

Lewis et al. 2020

[Retrieval-Augmented Generation · arxiv.org/abs/2005.11401](https://arxiv.org/abs/2005.11401)



Transformer Explainer