


Zničí nás AI?
Vezme nám práci?
Myslí? Ví, co říká?

Nejvíce se bojíme toho, čemu nerozumíme.

Tak to pojďme rozebrat.



Většina věcí po mně už nikdy nefungovala.
Ale vždycky jsem se něco naučil.

Kočka sedí na ...

střeše gauči zemi stole ...

Gratuluju. Právě jste si zahráli na language model.

Našeptávač z mobilu. Jen hodně, hodně velký.

Co je uvnitř? Jen minimum.

text Kočka sedí na

tokeny Ko čka · sed í · na

čísla 33185 51851 10412 556 898 → vektory čísel


síť neuronová síť: miliardy naučených čísel

výstup skóre pro každý možný další token

Uvnitř sítě se každý token může „podívat“ na předchozí text. Tomu se říká attention.

Nevypadne odpověď. Vypadne rozdělení.

Kočka sedí na ...



Ostatní: 28 % dohromady, rozprostřeno mezi desítky tisíc tokenů.

ilustrativní čísla, slova místo tokenů

A teď hodíme kostkou

T = 1.0

A  64 %

B  24 %

C  9 %

D  3 %

T = 0.2

A  99 %

B | <1 %

C | <1 %

D | <1 %

T = 1.2

A  59 %

B  25 %

C  11 %


D  5 %

Kostka, která před každým hodem změní pravděpodobnosti svých stěn podle všeho, co zatím viděla.

Stochastický ≠ náhodný chaos.

ilustrativní čísla

A znovu. A znovu. A znovu.



Kočka sedí na



·st

Kočka sedí na st



ře

Kočka sedí na stře



še

Kočka sedí na střeše



.

Tokeny podle o200k_base, konkrétní volby ilustrativní.


Odkud to umí? Z textu. Hodně textu.

Kočka sedí na **rohožce**

Hlavní město Austrálie je **Canberra**

```
def is_even(n): return n % 2 == 0
```

zakryj další token → model hádá → porovnej
→ maličko uprav naučená čísla → znovu
× **biliony tokenů**



Aby dobře doplňoval text, učí se jazyk, fakta, kód, styl a vztahy.

ilustrace, slova místo tokenů

Co z toho vyleze? GPT-2, 2019

vstup (lidský)	Fiktivní zpráva: v Andách objevili stádo jednorožců, kteří mluví anglicky.
pokračování	Článek v novinovém stylu. Vymyšlený biolog Jorge Pérez. Citace „vědců“.

Plynulý text ve správném žánru. Rozvíjí zadanou fikci. Není to ověřování zprávy.

české shrnutí skutečné ukázky: Radford et al. 2019, tab. 13

Base model není asistent

prompt Napiš francouzsky krátký příběh: žába cestuje časem do antického Řecka.

GPT-3 (base) Další zadání: příběh o dítěti a hrách bohů. Příběh o mladíkovi v jiné době. Příběh o dítěti s imaginárním přítelem...

Umí pokračovat v textu. Roli pomocníka ale nemá zaručenou.

české shrnutí skutečných výstupů: Ouyang et al. 2022, obr. 42

Naučíme ho formát konverzace

Uživatel: Přelož „dobrý den“ do angličtiny.

Asistent: Good morning / Good afternoon.

Uživatel: Shrň tenhle e-mail jednou větou.

Asistent: Klient posouvá schůzku na čtvrtek.

Lidé napíší obě strany dialogu. Tisíce takových ukázek.

Pořád doplňuje dokument. Jen dokument teď vypadá jako konverzace.

ilustrace

Která odpověď je lepší?

Vysvětli mi jednu větu, co je token.

odpověď A

Tokenizace má dlouhou historii. Začněme tím, jak počítače kódují znaky... (a dalších pět odstavců)

odpověď B

Kousek textu, se kterým model pracuje: někdy celé slovo, někdy jen jeho část.

✓ **vybráno**

Lidé porovnávají. Model se posouvá k odpovědím, které hodnotitelé preferují.

ilustrace, ne skutečný anotační záznam

Stejný prompt, po post-trainingu

prompt	Napiš francouzsky krátký příběh: žába cestuje časem do antického Řecka.
GPT-3 (base)	Další zadání dalších příběhů...
InstructGPT	Příběh o ztracené, unavené žábě, která hledá cestu do starého Řecka.

Stejný motor. Jiné chování.


české shrnutí skutečných výstupů: Ouyang et al. 2022, obr. 42

Tři kroky k chatbotovi



Nejdřív jsme model naučili pokračovat v textu. Pak jsme ho naučili, jak má pokračovat, když po něm něco chceme.

Uvnitř asistenta pořád běží tentýž motor.



Výsledek je odhad dalšího tokenu. Ne vyhledaný fakt.


Proč halucinuje?

**Zní to jako odpověď.
To nezaručuje pravdu.**

Model může říct „nevím“. Generování ale nezaručuje, že správně pozná kdy.

$$2837 \times 491 = ?$$

Kde jste v té mašině viděli násobičku?




Když mám kalkulačku, použiju kalkulačku.

Co v tréninku nenajde

„Kolik teď stojí bitcoin?“


„Co říká naše interní směrnice o cestovním?“

Trénink někdy skončil. A pokud naše dokumenty nedostal, nemá se o co opřít.




Najdeme podklady. Přidáme je k otázce.

Agent? Tohle ve smyčce.



LLM není celý agent. Je to jedna součástka systému.

Dosáhl 18 let?



Nedělej z deterministického problému probabilistický jen proto, že máš LLM.

Je to stížnost?

„No paráda, zase mi to přišlo rozbitý.“

```
if "paráda" in msg:  
    return PRAISE  
# ...a 4000 dalších výjimek
```

LLM



complaint


praise

question

nejisté → člověk

Tady rychle přibývají výjimky. Tady se model může hodit.

Deterministic software + probabilistic capabilities



DON'T PANIC

It's just software.
Very weird software.

Don't replace certainty with probability
unless probability solves a problem certainty can't.

Kam dál

Transformer Explainer

poloclub.github.io/transformer-explainer

Radford et al. 2019: GPT-2

cdn.openai.com/better-language-models/...multitask_learners.pdf

Ouyang et al. 2022: InstructGPT

arxiv.org/abs/2203.02155

Karpathy: Deep Dive into LLMs like ChatGPT

youtube.com/watch?v=7xTGNNLPyMI



Transformer Explainer