


Zničí nás AI?
Vezme nám práci?
Myslí? Ví, co říká?

Nejvíce se bojíme toho, čemu nerozumíme.

Tak to pojďme rozebrat.



Většina věcí po mně už nikdy nefungovala.
Ale vždycky jsem se něco naučil.

Kočka sedí na ...

střeše gauči zemi stole ...

Gratuluju. Právě jste si zahráli na language model.

LLM nevidí text. Dostává tokeny.

Ko	čka	· sed	í	· na	· st	ře	še	·	9 tokenů
33185	51851	10412	556	898	420	38132	13136	13	

The	· cat	· sits	· on	· the	· roof	·	7 tokenů
976	9059	38174	402	290	16367	13	

Tokenizer o200k_base. Tečka · je mezera. Čísla pod tokeny jsou jejich ID ve slovníku.

Tokeny se změní na čísla


· sed → 10412 → [0.12, -0.83, 0.40, ...]

· na → 898 → [-0.51, 0.07, 0.93, ...]

· st → 420 → [0.66, 0.21, -0.18, ...]


+ pozice v textu

Schematické hodnoty. Reálně stovky až tisíce čísel na token.



Schéma, ne měření: co se používá podobně, skončí blízko.


Na co se mám dívat?



Když zpracovávám tento token, které části kontextu jsou pro něj důležité?

Sytost modré = váha attention. Schéma, ne změřené váhy; slova místo tokenů.

Opakuj. Hodněkrát.




**Žádná ručně napsaná
tabulka odpovědí.**

Architektura + miliardy naučených
čísel. Parametrů.

Nevypadne odpověď. Vypadne rozdělení.

Kočka sedí na ... → logits → **softmax** → pravděpodobnosti



Ostatní: 28 % dohromady, rozprostřeno mezi desítky tisíc tokenů.

Ilustrativní čísla, slova místo tokenů

A teď hodíme kostkou

T = 1.0

A  64 %

B  24 %

C  9 %

D  3 %

T = 0.2

A  99 %

B | <1 %

C | <1 %

D | <1 %

T = 1.2

A  59 %

B  25 %

C  11 %


D  5 %

Kostka, která před každým hodem změní pravděpodobnosti svých stěn podle všeho, co zatím viděla.

Stochastický ≠ náhodný chaos.

Syntetické logits [3, 2, 1, 0], $\text{softmax}(\text{logits} / T)$. Pořadí se nemění, mění se poměry.

A znovu. A znovu. A znovu.



Kočka sedí na



·st

Kočka sedí na st



ře

Kočka sedí na stře



še

Kočka sedí na střeše



.

Tokeny podle o200k_base, konkrétní volby ilustrativní.

Tak proč je to tak chytré?

Hlavní město Austrálie je ... → fakta

def is_even(n): return ... → kód

„Le chat dort.“ = „Kočka ...“ → překlad

Pokud $A > B$ a $B > C$, pak A ... → struktura

Aby model dobře předpovídal text, učí se vzory a vztahy použitelné i pro překlad, kód a řešení úloh.

Potočíme pár miliard knoflíků

text: Kočka sedí na rohožce.

model: Kočka sedí na ...

• st  40 %

• ro  3 %


Ilustrativní pravděpodobnosti.

skutečný další token v textu: •ro


chyba → malá úprava parametrů → znovu

× biliony tokenů

Pak post-training: instrukce, preference, odměny.



Co mají LLM společného s JPEGem?



Parametry nejsou databáze dokumentů.

LLM není JPEG. Je to analogie pro intuici, ne technický popis.

Proč halucinuje?


```
while not done:  
    probs = model(context)      # vždycky nějaké rozdělení  
    token = sample(probs)      # vždycky nějaký token  
    context += token
```

Věrohodné pokračování není záruka pravdy.

Model může říct „nevím“. Generování ale nezaručuje, že správně pozná kdy.

$$2837 \times 491 = ?$$

Kde jste v té mašině viděli násobičku?



Když mám kalkulačku, použiju kalkulačku.

Tak mu dejme nástroje



LLM není celý agent. Je to jedna komponenta.

Agent je smyčka: zvol akci, spust' tool, přečti výsledek, pokračuj, nebo skonči.

Dva světy

Deterministic

pravidla

výpočty

validace

autorizace

DB constraints

workflows

Probabilistic

interpretace jazyka

klasifikace nejasného vstupu

extrakce

sumarizace

generování

fuzzy matching

Dosáhl 18 let?

X

birth_date



LLM



„ano, asi jo“

✓

birth_date



věk(d, dnes) >= 18



true

Nedělej z deterministického problému probabilistický jen proto, že máš LLM.

Je to stížnost?

„No paráda, zase mi to přišlo rozbitý.“

```
if "paráda" in msg:  
    return PRAISE  
# ...a 4000 dalších výjimek
```

LLM



complaint


praise

question

nejisté → člověk

Tady rychle přibývají výjimky. Tady se model může hodit.

To nejlepší z obou světů



DON'T PANIC

It's just software.
Very weird software.

Don't replace certainty with probability
unless probability solves a problem certainty can't.

Kam dál

Transformer Explainer

poloclub.github.io/transformer-explainer

Vaswani et al. 2017: Attention Is All You Need

arxiv.org/abs/1706.03762

Ouyang et al. 2022: InstructGPT

arxiv.org/abs/2203.02155

Lewis et al. 2020: Retrieval-Augmented Generation

arxiv.org/abs/2005.11401

Karpathy: Deep Dive into LLMs like ChatGPT

youtube.com/watch?v=7xTGNNLPyMI



Transformer Explainer